

Universidade Federal do Piauí - UFPI
Centro de Tecnologia - CT
Programa de Pós-Graduação em Engenharia Elétrica -
PPGEE

Aplicação de Redes Neurais Convolucionais na Detecção de Nódulos Pulmonares Malignos

Joyce Moura Silva

Resumo. *O câncer de pulmão representa uma das principais causas de morte no mundo, com 1,8 milhão de mortes em 2022%¹. A tomografia computadorizada é indispensável para o diagnóstico precoce da doença, aumentando as chances de detecção e tratamento nos estágios iniciais. No entanto, a análise manual de grandes quantidades de imagens médicas é um trabalho exaustivo e propenso a erros, pois requer a distinção atenta entre estruturas pulmonares e outras áreas anatômicas. Nesse contexto, este projeto propõe a aplicar Redes Neurais Convolucionais na detecção de nódulos pulmonares malignos, que oferecem alta eficiência e velocidade na análise de imagens médicas. A abordagem inclui a utilização da LIDC-IDRI, uma base de dados com imagens de tomografias, além do uso de técnicas de segmentação e aumento de dados, com o objetivo de aprimorar a precisão e agilidade na detecção de nódulos. Dessa forma, espera-se que os resultados contribuam para um diagnóstico mais preciso. Consequentemente, visando um melhor desempenho para auxiliar na avaliação de exames.*

1. Introdução

Em 2020, no Brasil, foram registrados 16.009 óbitos por câncer de pulmão entre homens e 12.609 entre mulheres. Esses números representam um perigo estimado de 15,46 mortes para cada 100 mil homens e de 11,65 para cada 100 mil mulheres (Brasil, 2022; INCA, 2020). Além disso, Segundo (Ferlay et al. 2021; Sung et al. 2021), uma em cada cinco pessoas desenvolverá câncer durante sua vida.

A Tomografia Computadorizada (TC) é um dos métodos mais eficazes para diagnóstico inicial, sendo um exame não invasivo que gera imagens detalhadas de alta qualidade em tons de cinza, usadas na análise de diversas lesões, incluindo as pulmonares (Dolejši, 2007), sendo o método favorito dos especialistas por tais feitos, como dito por (Yan et al. 2016). Todavia, a detecção de nódulos pulmonares malignos em tais imagens requer uma análise aprofundada, que pode ser exaustiva devido ao grande número de imagens e à necessidade de distinguir estruturas pulmonares de outros órgãos e tecidos.

Nos últimos anos, as CNNs (do inglês, *Convolutional Neural Networks*) têm se destacado pela sua atuação na identificação de nódulos pulmonares em imagens tomográficas, por sua capacidade de identificar padrões sutis e complexos nas imagens (Xie et al. 2019; Eun et al. 2018; Jiang et al. 2018). Essa abordagem vai além dos métodos tradicionais, pois é capaz de analisar diversos aspectos da imagem, como textura, densidade

¹<https://gco.iarc.fr/today/en/fact-sheets-populations#global>

e tamanho das estruturas, permitindo uma comparação mais precisa entre as imagens e o reconhecimento de padrões.

Com base nisso, este projeto propõe a utilização de CNNs para identificar nódulos malignos em imagens de TC, com o objetivo de acelerar e otimizar o diagnóstico. Ao extrair e analisar padrões complexos nas imagens, a metodologia busca fornecer uma ferramenta automática que apoie os médicos na tomada de decisões, classificando com maior precisão a malignidade dos nódulos. Dessa forma, espera-se não apenas diminuir o tempo de análise, como também aumentar a confiabilidade dos diagnósticos, o que resultará em intervenções mais rápidas e eficazes no tratamento do câncer de pulmão.




Figura 1. Tomografia pulmonar. Fonte: (Silva et al. 2007)

2. Fundamentação Teórica

2.1. Visão Computacional e Processamento de Imagens

A visão computacional é um termo abrangente, que envolve diversos aspectos da análise visual computacional (Brown, 1984). Seu propósito é capacitar os computadores a reconhecer e processar dados de maneira semelhante às pessoas, instruindo-os a reconhecer diferentes objetos vistos por diversos dispositivos (Almeida et al. 2019).

De acordo com (Marques e Vieira et al. 1999), é possível categorizar as aplicações de processamento de imagens em duas categorias distintas, sendo: o aprimoramento de dados pictóricos para interpretação humana (visão computacional) e a análise automática por computador de informações extraídas de uma cena (reconhecimento de padrões). Dentro dessas categorias temos Processamento Digital de Imagens (PDI) que refere-se à transformação de uma imagem continuamente para que se possa extrair mais facilmente as informações contidas nela (Pedrini e Schwartz et al. 2008).

2.2. Aprendizagem Profunda e Redes Neurais Convolucionais

A Aprendizagem Profunda (AP) é uma das subáreas mais relevantes de Aprendizado de Máquina (AM). De acordo com (Steinheiser et al. 2020), essa subárea tem como principal essência a abstração do sistema neural humano, que pode ser representado através de uma Rede Neural Artificial (RNA).

A AP envolve técnicas que utilizam múltiplas camadas de processamento não linear para reconhecer padrões de forma semelhante ao cérebro (LeCun, Bengio e Hinton,

2015). Entre essas técnicas, destacam-se as CNNs, que são uma arquitetura inspirada na biologia, capaz de aprender hierarquias de diferentes níveis de características (LeCun et al. 1998). A rede coleta explicitamente as características dos padrões visuais apresentados como entrada e as categoriza com base nas informações obtidas.

2.3. Tomografia Computadorizada

O exame de Tomografia é utilizado para identificar tumores, fraturas e obstruções circulatórias e outras mudanças nas estruturas orgânicas e outras alterações teciduais. Essa tecnologia é capaz de detectar pequenas variações na densidade dos tecidos, inferiores a 1%, o que possibilita diagnósticos precoces, facilitando o tratamento e melhorando as chances de recuperação do paciente (Bontrager, 2003). Além disso, essa técnica é capaz de produzir imagens detalhadas e em 3D do corpo humano, o que possibilita aos médicos diagnósticos mais precisos e exames menos invasivos (Silva et al. 2023).

3. Metodologia

Visando alcançar o objetivo geral do trabalho, organizou-se a metodologia em cinco etapas, ilustradas na Figura 2.




Figura 2. Metodologia proposta.

Na primeira etapa, será realizada uma revisão da literatura para identificar os trabalhos mais relevantes na área de visão computacional, com foco em CNNs aplicadas em TC. Para essa revisão, serão consultadas bases de dados como SOL-SBC², Google Acadêmico³, IEE Explorer⁴, Scopus⁵, a fim de garantir a amplitude e qualidade das referências e conhecimentos.

Na segunda etapa, será utilizada a base de imagens LIDC-IDRI (Armato et al. 2011), que oferece um conjunto robusto de TC, contém cerca de 245.000 imagens, que também oferecem informações sobre sutileza, estrutura interna, calcificação, esfericidade, espiculação, textura, malignidade. Sendo uma fonte consolidada para a coleta de dados.

Na terceira etapa, após a entrada da base dados, será necessário um pré-processamento das imagens, para que o modelo aprenda com dados de alta qualidade e relevância. Isso inclui redimensionamento, aplicação de filtros para realçar regiões importantes e segmentação da região de interesse para remover artefatos externos que possam atrapalhar o treinamento, para focar nas áreas mais importantes das imagens.

²<https://sol.sbc.org.br/>

³<https://scholar.google.com/>

⁴<https://ieeexplore.ieee.org>

⁵<https://www.scopus.com/>

A quarta etapa, é o de aumento de dados, o objetivo é evitar o overfitting, fornecendo mais exemplos para o modelo e equilibrar classes desbalanceadas, para isso serão explorada com técnicas baseadas em GANs (do inglês, *Generative Adversarial Networks*) e *Autoencoders*, para gerar novos exemplos a partir dos dados existentes. Em seguida, fazer divisão dos dados em conjuntos de treino, validação e teste.

E por fim, na quinta e última etapa, serão aplicados diferentes modelos de CNNs que serão empregados para a detecção de nódulos pulmonares. Modelos como *YOLO* (Redmon et al. 2016), *Faster R-CNN* (Ren et al. 2016) e *3D CNNs* (Ji et al. 2012), entre outros, que vão ser testados com o intuito de obter o melhor desempenho possível. Os resultados obtidos serão analisados e comparados com as demais literaturas da área, permitindo uma avaliação crítica da eficácia das abordagens adotadas.

4. Resultados

Espera-se que os resultados demonstrem que o uso de CNNs para detecção de nódulos pulmonares malignos em imagens de TC podem aumentar significativamente a precisão e a velocidade do diagnóstico em comparação aos métodos tradicionais. Acredita-se que técnicas de pré-processamento, como segmentação e aumento de informações por meio de GANs e *Autoencoders*, melhorem a qualidade das imagens analisadas, permitindo que os modelos identifiquem padrões mais sutis e complexos.

Também é esperado que o desenvolvimento de um método automático mais eficiente para identificar nódulos pulmonares, que possa ser facilmente incorporado aos sistemas hospitalares existentes ou em sistemas como o CAD (do inglês, *Computer-Aided Detection*). Este método será útil para a comunidade acadêmica ao fornecer uma metodologia inovadora e eficiente para o diagnóstico precoce do câncer de pulmão, facilitando futuras pesquisas e aprimoramentos na área de visão computacional aplicada à medicina.

Os resultados também deverão mostrar uma redução nos custos operacionais dos hospitais, uma vez que a automatização do processo de detecção diminui a necessidade de intervenção manual extensiva, reduzindo o tempo e os recursos necessários para análises diagnósticas.

Referências

ALMEIDA, C. C. d. et al. *Identificação e classificação de imagens usando rede neural convolucional e machine learning: implementação em sistema embarcado*. 2019. 1 recurso online (202 p.) Tese (doutorado) - Universidade Estadual de Campinas, Faculdade de Engenharia Mecânica, Campinas, SP. Disponível em: <https://hdl.handle.net/20.500.12733/1638173>.

ARMATO III, S. G. et al. *The lung image database consortium (LIDC) and image database resource initiative (IDRI): a completed reference database of lung nodules on CT scans*. *Medical Physics*, v. 38, n. 2, p. 915–931, 2011.

BRASIL. *DATASUS - Tabnet*. Brasília: Ministério da Saúde, 2022.

BONTRAGER, K. *Tratado de técnica radiológica e base anatômica*. 5. ed. Rio de Janeiro, Brasil: Guanabara Koogan, 2003.

BROWN, C. M. *Computer vision and natural constraints*. *Science*, v. 224, n. 4648, p. 1299-1305, 1984.

DOLEJŠÍ, M. *Detection of Pulmonary Nodules from CT Scans*. 2007. Tese (Doutorado) — Faculty of Electrical Engineering, Czech Technical University in Prague, 2007.

EUN, H.; KIM, D.; JUNG, C.; KIM, C. *Single-view 2D CNNs with fully automatic non-nodule categorization for false positive reduction in pulmonary nodule detection*. *Computer Methods and Programs in Biomedicine*, v. 165, p. 215–224, 2018.

FERLAY, J. et al. *Cancer statistics for the year 2020: an overview*. *International Journal of Cancer*, Apr. 2021. DOI: 10.1002/ijc.33588.

GOODFELLOW, I. J. et al. *Generative adversarial networks*. 2014.

INSTITUTO NACIONAL DE CÂNCER JOSÉ ALENCAR GOMES DA SILVA. *Atlas on-line de mortalidade*. [Rio de Janeiro: INCA, 2020a].

JIANG, H. et al. *An automatic detection system of lung nodules based on multigroup patch-based deep learning networks*. *IEEE Journal of Biomedical and Health Informatics*, v. 22, n. 4, p. 1227-1237, 2018.

JI, S.; XU, W.; YANG, M.; YU, K. *3D convolutional neural networks for human action recognition*. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 35, n. 1, p. 221-231, 2013. DOI: 10.1109/TPAMI.2012.59.

LECUN, Y.; BENGIO, Y.; HINTON, G. *Deep learning*. *Nature*, v. 521, n. 7553, p. 436–444, 2015.

LECUN, Y. et al. *Gradient-based learning applied to document recognition*. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998.

MARQUES FILHO, O.; VIEIRA NETO, H. *Processamento digital de imagens*. Rio de Janeiro: Brasport, 1999.

PEDRINI, H.; SCHWARTZ, W. R. *Análise de imagens digitais: princípios, algoritmos e aplicações*. São Paulo: Cengage Learning, 2008.

REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. *You only look once: unified, real-time object detection*. 2016.

REN, S.; HE, K.; GIRSHICK, R.; SUN, J. *Faster R-CNN: towards real-time object detection with region proposal networks*. 2016.

STEINHEISER, P. W. et al. *Estudo do desempenho da detecção de objetos em exames de AgNOR*. Florianópolis: [s.n.], 2020.

SUNG, H. et al. *Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries*. *CA: Cancer Journal for Clinicians*, v. 71, n. 3, p. 209-249, Feb. 2021. DOI: 10.3322/caac.21660.

SILVA, A. C. da; SILVA, D. de S. M.; SILVA, M. do S. de L. *Diagnóstico por imagem e medicina: sua importância como aplicação multidisciplinar para a saúde*. Seven Editora, [S. l.], p. 1528–1533, 2023.

SILVA, V. A. d. et al. *Hamartoma pulmonar como diagnóstico diferencial de metástase de carcinoma de mama: relato de caso*. *Jornal Brasileiro de Pneumologia*, v. 33, p. 738–742, 2007.

YAN, X. et al. (2016). *Classification of lung nodule malignancy risk on computed tomography images using convolutional neural network: A comparison between 2d and 3d strategies*. In Asian Conference on Computer Vision, pages 91–101. Springer.

XIE, H. et al. *Automated pulmonary nodule detection in CT images using deep convolutional neural networks*. Pattern Recognition, v. 85, p. 109–119, 2019.