

**TÍTULO DO PROJETO:** Aplicação de Redes Neurais Convolucionais 3D na classificação do carcinoma pulmonar de células não pequenas

**EIXO TEMÁTICO:** Eixo Temático III - **Tecnologia da Informação:** Tecnológica em Saúde.

## **RESUMO EXPANDIDO**

Atualmente o câncer é o segundo maior fator de mortalidade no mundo, conforme apontado pela Organização Mundial da Saúde (OMS) (OMS, 2018). Tendo o tabagismo como principal fator de risco para o desenvolvimento desse tipo de tumor, associado a cerca de 85% dos casos diagnosticados (INCA, 2022). No caso do câncer pulmonar de células não pequenas afeta, o tabagismo afeta principalmente as pessoas que são fumantes, ou até mesmo as pessoas que apenas respiram a fumaça do cigarro de outras pessoas. O câncer do pulmão de células não pequenas é raro em pessoas mais jovens, e a maioria das pessoas são diagnosticadas entre as idades de 50 e 70 anos (Ada, 2022). Por isso sua detecção e classificação precoce ainda representa um desafio clínico. Isso ocorre principalmente porque, nas fases iniciais, os nódulos pulmonares podem apresentar características muito sutis, com baixo contraste e alta semelhança com estruturas saudáveis, o que dificulta sua diferenciação por meio da análise visual convencional em exames de tomografia computadorizada.

Diante disso, provasse a necessidade do desenvolvimento de ferramentas tecnológicas que auxiliem os profissionais de saúde na detecção e na classificação precisa dessas lesões. Assim, o desenvolvimento deste projeto é aprimorar os métodos de diagnóstico assistido por imagem, contribuindo diretamente para a melhoria dos prognósticos dos pacientes e para a otimização dos processos na área da saúde.

## **PROBLEMÁTICA**

De acordo com a Agência Internacional de Pesquisa sobre o Câncer (IARC), o câncer de pulmão foi o tipo mais comum em todo o mundo em 2022, com 2,5 milhões de novos casos e 1,8 milhão de óbitos, representando 12,4% de todos os novos diagnósticos (IARC 2022). No Brasil, em 2020, foram registrados 16.009 óbitos por câncer de pulmão entre homens e 12.609 entre mulheres. Esses números representam um perigo estimado de 15,46 mortes para cada 100 mil homens e de 11,65 para cada 100 mil mulheres (Brasil, 2022; INCA, 2020). Além disso, as estimativas do Instituto Nacional de Câncer (INCA) para 2023 indicaram que o câncer de pulmão é o terceiro mais frequente entre homens, com 18.020 novos casos, e o quarto entre mulheres, com 14.540 casos. Globalmente, ocupa a primeira posição em incidência entre homens e a terceira entre mulheres (INCA, 2022).

De modo geral, o câncer de pulmão é classificado em dois grupos principais: carcinoma de pequenas células (*oat cell carcinoma*) e carcinoma de não pequenas células (CPCNP) (*non-oat cell carcinoma*). Este último corresponde a aproximadamente 85% dos casos e engloba os subtipos adenocarcinoma, carcinoma de células escamosas e carcinoma de grandes células, e outros subtipos, que são muito menos comuns (American Cancer Society, 2024)

## JUSTIFICATIVA

A Tomografia Computadorizada (TC) é um dos principais métodos de diagnóstico inicial de tumores, por ser um exame não invasivo que gera imagens detalhadas em tons de cinza, permitindo a análise precisa de diversas lesões, incluindo as pulmonares (Dolejší, 2007). Por essas características, é considerada o método preferido pelos especialistas, conforme apontado por (Yan et al. 2016). Ademais, a identificação e classificação de nódulos em estágios iniciais podem ser particularmente desafiadoras, mesmo para profissionais altamente experientes. Isso se deve ao fato de que nódulos pequenos apresentam baixo contraste e, muitas vezes, estão localizados em regiões com características visuais semelhantes ao tecido saudável, dificultando a diferenciação entre lesões malignas e benignas (Kamiya et al. 2011, Silva et al. 2005).

O uso das CNNs (do inglês, *Convolutional Neural Networks*) têm se destacado na detecção e classificação de nódulos pulmonares em imagens de TC, graças à sua capacidade de identificar padrões sutis e complexos (Xie et al. 2019, Eun et al. 2018, Jiang et al. 2018). Diferentemente dos métodos tradicionais, essas redes conseguem analisar múltiplas características das imagens — como textura, densidade e tamanho —, promovendo uma análise mais robusta e acurada. Especificamente, as arquiteturas tridimensionais (3D) das CNNs são particularmente eficazes nesse contexto, pois permitem a análise volumétrica das imagens, capturando as relações espaciais entre os voxels, já que o TC é naturalmente 3D (Chen and Xie 2024).

## OBJETIVOS

### Geral

Aplicar e avaliar modelos de CNNs 3D na classificação do carcinoma pulmonar de não pequenas células em imagens de tomografia computadorizada, a fim de investigar seu desempenho como ferramenta de apoio ao diagnóstico.

### Específicos

1. Realizar o pré-processamento do conjunto de dados;
2. Utilizar técnicas de aumento de dados;
3. Treinar e validar CNNs 3D, utilizando técnicas de ajuste de hiperparâmetros;
4. Avaliar o desempenho dos modelos aplicados e compará-los com a literatura;
5. Analisar e discutir os resultados, destacando os benefícios e limitações do uso de CNNs 3D.

## METODOLOGIA

Visando alcançar o objetivo geral do trabalho, organizou-se a metodologia em quatro etapas, ilustradas na Figura 1.



Figura 1. Metodologia proposta.

Na primeira etapa, será realizada uma revisão da literatura para identificar os trabalhos mais relevantes na área de visão computacional, com foco em CNNs 3D aplicadas em TC. Para essa revisão, serão consultadas bases de dados como SOL-SBC<sup>1</sup>, Google Acadêmico<sup>2</sup>, IEE Explorer<sup>3</sup>, Scopus<sup>4</sup>, a fim de garantir a amplitude e qualidade das referências e conhecimentos.

Na segunda etapa, será utilizada uma base de imagens composta por um conjunto de dados de nódulos pulmonares com anotação do tipo de câncer baseado em histopatologia (Jian et al., 2024). Esse conjunto contém 330 imagens de TC de nódulos provenientes de 95 pacientes, anotados e classificados como: benigno, adenocarcinoma e carcinoma de células escamosas. As imagens estão disponíveis nos formatos *BMP*, *MHD* e *DICOM*. Onde após a entrada da base dados, será necessário um pré-processamento das imagens, para que o modelo aprenda com dados de alta qualidade e relevância. Isso inclui redimensionamento, aplicação de filtros para realçar regiões importantes e segmentação da região de interesse para remover artefatos externos que possam atrapalhar o treinamento, para focar nas áreas mais importantes das imagens.

A quarta terceira, é o de aumento de dados, o objetivo é evitar o *overfitting*, fornecendo mais exemplos para o modelo e equilibrar classes desbalanceadas, para isso serão explorada com técnicas baseadas em GANs (do inglês, *Generative Adversarial Networks*) e *Autoencoders*, para gerar novos exemplos a partir dos dados existentes. Em seguida, fazer divisão dos dados em conjuntos de treino, validação e teste.

E por fim, na quarta e última etapa, será realizado o treino e a validação, onde vão ser aplicados diferentes modelos de CNNs 3D que serão empregados para a classificação de nódulos pulmonares. Modelos que vão ser testados com o intuito de obter o melhor desempenho possível. Os resultados obtidos serão analisados e comparados com as demais literaturas, permitindo uma avaliação crítica da eficácia das abordagens adotadas.

## **Acompanhamento e Avaliação do Projeto Durante a Execução**

O projeto de pesquisa será desenvolvido no Laboratório de Pesquisas Aplicadas à Visão e Inteligência Computacional (PAVIC) da Universidade Federal do Piauí (UFPI), campus Senador Helvídio Nunes de Barros. O acompanhamento será realizado pelo professor orientador do projeto, por meio de reuniões semanais ou quinzenais, destinadas à avaliação e ao acompanhamento de cada fase do desenvolvimento.

## **RESULTADOS ESPERADOS**

Espera-se que os resultados demonstrem que o uso de CNNs 3D para classificação de câncer pulmonar de células não pequenas em imagens de TC podem aumentar significativamente a precisão e a velocidade do diagnóstico em comparação aos métodos tradicionais. Acredita-se que técnicas de pré-processamento, e aumento de informações por

---

<sup>1</sup> <https://sol.sbc.org.br/>

<sup>2</sup> <https://scholar.google.com/>

<sup>3</sup> <https://ieeexplore.ieee.org>

<sup>4</sup> <https://www.scopus.com/>

meio de GANs e *Autoencoders*, melhorem a qualidade das imagens analisadas, permitindo que os modelos identifiquem com melhor precisão padrões mais complexos.

Também é esperado que o desenvolvimento de um método automático mais eficiente para identificar subtipos de carcinoma pulmonar de células não pequenas, que possa ser facilmente incorporado aos sistemas hospitalares existentes ou em sistemas como o CAD (do inglês, *Computer-Aided Detection*). Este método será útil para a comunidade acadêmica ao fornecer uma metodologia inovadora e eficiente para o diagnóstico precoce do câncer de pulmão, facilitando futuras pesquisas e aprimoramentos na área de visão computacional aplicada à medicina.

**CRONOGRAMA DE ATIVIDADES**

ATIVIDADE	2025		2026	
	1º Semestre	2º Semestre	1º Semestre	2º Semestre
Revisão bibliográfica	X	X	X	X
Pré-Processamento de imagens	X	X		
Aumento de dados	X	X		
Escolha e implementação dos modelos		X	X	
Treinamento e validação dos modelos		X	X	X
Análise, comparação e avaliação dos modelos			X	X
Escrita e submissão do artigo científico		X	X	X
Qualificação				X
Defesa da Dissertação				X

**REFERÊNCIAS**

ADA. Câncer do pulmão de células não pequenas. 2022. Disponível em: <https://ada.com/pt/conditions/non-small-cell-lung-cancer/>.

AMERICAN CANCER SOCIETY. Cancer A-Z. About lung cancer. Atlanta: American Cancer Society, 2024. Disponível em: <https://www.cancer.org/cancer/types/lung-cancer/about/what-is.html>.

BRASIL. Ministério da Saúde. DATASUS. Tabnet. Brasília: Ministério da Saúde, 2022.

CHEN, Yujiang; XIE, Mei. Improved focus on hard samples for lung nodule detection. In: *6th International Conference on Control and Computer Vision. Proceedings [...]*. p. 21–26, 2024.

DOLEJŠÍ, M. Detection of Pulmonary Nodules from CT Scans. 2007. Phd. Faculty of Electrical Engineering, Czech Technical University in Prague, 2007.

EUN, Hyunjun et al. Single-view 2D CNNs with fully automatic non-nodule categorization for false positive reduction in pulmonary nodule detection. *Computer Methods and Programs in Biomedicine*, v. 165, p. 215–224, 2018. Disponível em: <https://api.semanticscholar.org/CorpusID:53011733>. Acesso em: 30 maio 2025.

IARC. Population Factsheets – Worldwide. 2022. Disponível em: <https://gco.iarc.fr/today/en/fact-sheets-populations#global>.

INCA. *Atlas on-line de mortalidade*. [Rio de Janeiro: INCA, 2020a].

INCA. Câncer de Pulmão. 2022. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/tipos/pulmao>.

JIANG, Hongyang et al. An automatic detection system of lung nodule based on multigroup patch-based deep learning network. *IEEE Journal of Biomedical and Health Informatics*, v. 22, p. 1227–1237, 2018. Disponível em: <https://api.semanticscholar.org/CorpusID:22730346>. Acesso em: 30 maio 2025.

JIANG, M., Chen, H., Zhang, Z. et al. A lung nodule dataset with histopathology-based cancer type annotation. *Scientific Data*, v. 11, n. 824, 2024. Disponível em: <https://doi.org/10.1038/s41597-024-03658-6>. Acesso em: 9 jul. 2025.

KAMIYA, Hisashi et al. Pulmonary nodules: a quantitative method of diagnosis by evaluating nodule perimeter difference to approximate oval using three-dimensional CT images. *Clinical Imaging*, v. 35, n. 2, p. 123–126, 2011. Disponível em: <https://www.sciencedirect.com/science/article/pii/S089970711000080X>. Acesso em: 30 maio 2025. DOI: <https://doi.org/10.1016/j.clinimag.2010.03.007>.

OMS. Cancer - World Health Organization. 2018. Disponível em: [https://www.who.int/health-topics/cancer#tab=tab\\_1](https://www.who.int/health-topics/cancer#tab=tab_1).

SILVA, Aristófanés C.; CARVALHO, Paulo Cezar P.; GATTASS, Marcelo. Diagnosis of lung nodule using semivariogram and geometric measures in computerized tomography images. *Computer Methods and Programs in Biomedicine*, v. 79, n. 1, p. 31–38, 2005. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0169260705000398>. Acesso em: 30 maio 2025. DOI: <https://doi.org/10.1016/j.cmpb.2004.12.008>.

XIE, Hongtao et al. Automated pulmonary nodule detection in CT images using deep convolutional neural networks. *Pattern Recognition*, v. 85, p. 109–119, 2019. Disponível em: <https://api.semanticscholar.org/CorpusID:53528758>. Acesso em: 30 maio 2025.

YAN, Xingjian et al. Classification of lung nodule malignancy risk on computed tomography images using convolutional neural network: a comparison between 2D and 3D strategies. In: *Computer Vision – ACCV 2016 Workshops*. Springer International Publishing, 2016. Disponível em: <https://api.semanticscholar.org/CorpusID:26883456>. Acesso em: 30 maio 2025.